



NRC 국책연구기관 연구직 과정 · 고급

LLM Agent 기반 연구 데이터 파이프라인

수집·정제·검증·문서화를 에이전트에게 맡기고, 해석과 판단은 연구자가 지킵니다

2026. 9. 16.(수) 09:30~17:00 · Webex 라이브

박주혜

학계와 업계를 아우르는 AI를, 쉽게 전해 드립니다.

AI 원리 · AI 리터러시 · 기업 AX

강사

박주혜

AI 원리 · AI 리터러시
기업 AX 교육

dmtgjh@naver.com

공공 · 정부 멘토링

과학기술정보통신부 AI·SW 마에스트로 멘토
한국환경공단 환경데이터 분석·활용 공모전 멘토
청년취업사관학교(새싹) AI 데이터 현직자 멘토
숙명여대 DACOS 데이터톤 심사위원

대학 · 아카데미

숙명여대 · 한양대 · 인하대
MS AI 스쿨 · 코드잇 · 패스트캠퍼스

기업 AX 강의

롯데그룹 Enterprise AI 활용 교육
삼성전자 Python 기초
SK그룹 HRD AI Workshop · 그래프 기반 스킬 분석
LS그룹 사내 AI 플랫폼 도입
롯데그룹 ChatGPT 활용 · 바이브코딩 · n8n AI 아키텍처
한국투자증권 생성형 AI와 SQL
현대인재개발원 디지털 전환과 인공지능

집필

실전 AX 리포트, 한 권으로 끝내는 직장인 AI 대학원 입학 바이블
ChatGPT 원칙과 실습 (윝김)

45분 수업하고 15분 쉽니다. 여섯 교시가 하나의 프로젝트로 이어집니다.

실습 공유 공간: https://padlet.com/dmtgjh/data_0916


1교시	09:30~10:15	환경 세팅과 오리엔테이션	무엇을 만들고 무엇을 남기는가
2교시	10:30~11:30	공공·국제 오픈데이터와 API	어떤 데이터가 어디에 있는가
11:30~13:00		점심	
3교시	13:00~13:45	API 문서 분석과 요청 구문 설계	어떻게 요청하는가
4교시	14:00~14:45	제1원칙과 API 수집·정제	어떻게 믿을 수 있게 가져오는가
5교시	15:00~15:45	웹크롤링·내부 자료, 그리고 통합	어떻게 하나로 붙이는가
6교시	16:00~16:45	검증·지표 추가·자동화	어떻게 매번 다시 돌리는가

SO WHAT 교시마다 다른 예제를 하지 않습니다. 저장소 하나를 열고 하루 종일 그 안에서 움직입니다.


오늘 끝나면 파이프라인 하나와 산출물 네 가지가 남습니다.

한 번 만들면 매달 다시 도는 구조. 노트북이 아니라 저장소를 가져가십니다

PIPELINE



OUTPUTS



SO WHAT 노트북 셀이 아니라 다시 실행할 수 있는 저장소를 가져가십니다.

네 교시가 하나의 프로젝트로 이어집니다.

09:30에 저장소를 열고 17:00까지 그 안에서만 움직입니다

09:30~10:30

1교시
소스를 파악한다

어떤 데이터가 어디에 있는가

10:30~11:30

2교시
명세서를 만들고 검증한다

어떻게 요청하는가

13:00~15:00

3교시
세 소스를 각각 가져온다

어떻게 믿을 수 있게 가져오는가

15:00~17:00

4교시
붙이고 자동화한다

어떻게 매번 다시 돌리는가

점심 11:30~13:00 · 휴식 14:00, 16:00

표준 스키마

source | indicator_code | region_code | period | value | unit | vintage | retrieved_at | source_url | missing_reason

SO WHAT 이 열 개 컬럼은 하루 종일 바뀌지 않습니다. 모든 실습이 이 모양으로 모입니다.

설치가 안 되셨어도 파이프라인은 직접 실행하십니다.

두 트랙 모두 같은 저장소, 같은 산출물을 봅니다

따라하기 트랙

준비물

Python 3.10+

VS Code

Claude Code · 계정



에이전트에게 직접 요청하고
결과를 검증합니다

접속 테스트 통과가 조건입니다

`python run.py --offline`

관전 + 파이프라인 트랙

준비물

Python 3.10+

VS Code

저장소 zip



강사 화면을 보며 따라오고
파이프라인은 직접 실행합니다

LLM 호출이 없어 망 제약이 있어도 됩니다

`python run.py --offline`

SO WHAT 차이는 에이전트에게 직접 시키느냐, 시키는 걸 보느냐뿐입니다.

첫 15분 안에 최종 결과물을 손에 쥐고 시작합시다

09:30~09:45 환경 점검. 3번이 안 되는 분은 관전 트랙으로 갑니다

	macOS	Windows
venv 생성	<code>python3 -m venv .venv</code>	<code>python -m venv .venv</code>
활성화	<code>source .venv/bin/activate</code>	<code>.venv\Scripts\activate</code>
이후	<code>pip · python</code> 동일	<code>pip · python</code> 동일

1 저장소 열기

터미널

```
VS Code · 파일 · 폴더 열기
```



기대 결과
research-data-pipeline 폴더가
왼쪽 탐색기에 보임

채팅창에 1 입력
안 되면 채팅창에 x를 남기고 관전 트랙으로 갑니다

2 파이프라인 실행

터미널

```
python run.py --offline
```



기대 결과
완료 · 292행
out/dashboard.html 생성

채팅창에 2 입력
안 되면 채팅창에 x를 남기고 관전 트랙으로 갑니다

3 에이전트 응답 확인

터미널

```
claude
```



기대 결과
저장소 설명이 돌아오면
따라하기 트랙 확정

채팅창에 3 입력
안 되면 채팅창에 x를 남기고 관전 트랙으로 갑니다

SO WHAT 2번까지 되면 오늘 전 과정을 따라오실 수 있습니다. 3번은 에이전트 실습용입니다.

01

공공·국제 오픈데이터와 API의 이해

09:30~10:30 · 어떤 데이터가 어디에 있는가

표준 스키마는 바뀌지 않습니다

국내 세 창구는 인증·응답 형식·지역 단위가 전부 다릅니다.

공공데이터포털 · KOSIS 공유서비스 · 부처별 오픈 API

창구	인증	응답	지역 단위	호출 제한
공공데이터포털	인증키 필요	JSON · XML	데이터셋마다 다름	일일 트래픽
KOSIS 공유서비스	인증키 필요	JSON · XML	전국 · 시도 · 시군구	발급 등급별
부처별 오픈 API	기관마다 다름	기관마다 다름	기관마다 다름	기관마다 다름

실습 소재는 KOSIS 인구동향조사. 인증키가 있는 분만 실시간 호출, 나머지는 스냅샷으로 진행합니다.

KEY ACTION

인증키는 지금 발급받으셔야 합니다

회원가입 · 로그인



활용신청 (승인 대기 있음)



인증키 발급



환경변수 KOSIS_API_KEY 설정

승인까지 며칠 걸릴 수 있습니다. 수업 최소 일주일 전 신청.

SO WHAT World Bank는 인증이 없어 첫 호출 실습으로 씁니다. KOSIS는 명세서까지, 호출은 키 있는 분만.

SDMX 구조 하나를 알면 OECD와 Eurostat이 한꺼번에 열립니다.

World Bank · OECD · IMF · Eurostat

SOURCES

World Bank	Indicators API · 인증 없음 첫 호출 실패
OECD	Data Explorer · SDMX 접근 경로 개편 이력, 재확인
IMF	SDMX 계열 데이터 API 거시·재정 지표
Eurostat	데이터브라우저 · SDMX API isoc_ 계열 디지털 지표

SDMX 구조

요청은 세 층으로 조립됩니다



<https://.../data/{dataflow}/{국가}.{지표}?startPeriod=2015>

dimension 순서와 codelist 값은 dataflow마다 다릅니다. 2교시에서 문서를 읽혀 명세서로 뽑는 이유입니다.

SO WHAT 국제 비교표는 국가별 공표연도가 달라 최신 가용 연도를 씁니다. 연도는 코드 북에 기록합니다.

API가 있다는 것과 연구에 쓸 수 있다는 것은 다릅니다.

이 간극을 메우는 게 오늘 6시간입니다

다섯 가지 제약

시계열 단절	조사 방식이 바뀌면 앞뒤가 이어지지 않음	→ 코드북에 단절 시점 기록
코드체계 개정	행정구역 · 산업분류 코드가 바뀜	→ 매핑 사전으로 흡수
잠정치와 확정치	공표 후 값이 바뀌어 과거 분석이 흔들림	→ 수집 시점 원본 보관
라이선스와 출처표기	이용약관과 표기 의무가 소스마다 다름	→ 레지스트리에 표기 문구 등록
망분리	기관 망에서 외부 API가 막힘	→ 스냅샷 모드로 구조 먼저 검증

VINTAGE

잠정치 공표 → 확정치 공표 → 값이 바뀜

재현하려면 수집 시점 원본과 기준(vintage)을 같이 남겨야 합니다.

출처 표기 세 가지

- 1 소스 이름과 요청 주소
- 2 수집 시각과 기준(확정 · 잠정)
- 3 이용약관의 표기 문구

SO WHAT 제약마다 대응이 파이프라인 안에 자리가 있습니다. 오후에 하나씩 코드로 박습니다.

문서만 읽고 코드를 짜면 첫 호출에서 깨집니다.

10:05 · exercises/01/README.md 의 프롬프트를 그대로 붙여넣습니다

TERMINAL · claude

> World Bank API로 한국 합계출산율 2015~2025년을 받아서 표로 보여줘.

코드를 작성하고 실행합니다. 11행이 돌아옵니다.

> 응답의 최상위 구조를 설명해줘. 딕셔너리야, 리스트야?

원소 2개짜리 리스트입니다. [0]은 페이징 메타, [1]은 관측치 배열입니다.

> 메타의 total과 per_page를 비교해서 뒷장이 남았는지 확인해줘.

total 11, per_page 500. 뒷장은 없습니다.

에이전트가 답을 내는 게 아니라, 검증 질문을 던지는 법을 배우는 시간입니다.

RESPONSE SHAPE

최상위가 딕셔너리가 아니라 리스트입니다

```
payload = [
  [0] { page, pages, per_page, total, lastupdated }
  [1] [ { indicator, countryiso3code, date, value }, ... ]
]
```

IF WRONG

→ payload["data"]로 접근하는 코드는 바로 깨집니다. 메타의 total이 per_page보다 크면 뒷장이 남은 것입니다.

그래서 문서를 읽었으면 반드시 한 번 때려보고 넘어갑니다.

SO WHAT 호출 한 번 해보고 구조를 확인한 뒤에 코드를 짭니다. 오늘 계속 반복할 원칙입니다.

빈칸 하나로 뭉겐 결측은 나중에 복원할 수 없습니다.

미조사 · 해당없음 · 비공개는 분석에서 다르게 다룹니다

WHY NOW

3

결측의 종류

수집 시점에만 알 수 있는 정보입니다. 그때 사유를 적지 않으면 이후 어느 단계에서도 알 방법이 없습니다.

missing_reason 컬럼이 이 셋을 담습니다

value 가 비어 있음



SO WHAT 오후에 이 셋을 강제하는 데이터 구조를 만듭니다. 사유가 없으면 행 생성 자체가 실패합니다.

갱신에 시간 단위가 적히는 소스가 오늘의 목표입니다.

평소 쓰시는 소스 세 개를 채워보세요. 막히는 칸이 자동화가 막히는 지점입니다

소스	API 있음	인증 필요	갱신 주기	갱신하는 데 걸리는 시간	잠정치 있음	담당
예) kosis 인구동향조사	예	예	월	반나절	예	본인

시간 단위



분 단위

잠정치가 예라면 확정 후 과거 분석이 흔들립니다. 오후에 vintage 관리로 다룹니다.

SO WHAT

마지막 두 칸이 오늘의 목표치입니다. 시간을 분으로, 잠정치를 재현 가능하게.

02

API 문서 분석과 요청 구문 설계

10:30~11:30 · 어떻게 요청하는가

표준 스키마는 바뀌지 않습니다

문서의 여덟 항목이 코드의 여덟 자리로 그대로 옮겨갑니다.

명세서 양식을 먼저 고정해야 매번 같은 모양이 나옵니다

문서에서 뽑는 것

endpoint	요청 주소, 경로 변수
params	필수 · 선택 파라미터
auth	인증 방식과 키 이름
response_shape	최상위 구조
data_path	관측치 목록까지의 경로
error_codes	오류 코드와 의미
pagination	쪽 처리와 총건수
rate_limit	호출 제한


코드에서 쓰이는 자리

→	URL 조립
→	params 딕셔너리
→	헤더 또는 쿼리에 키 삽입
→	파싱 분기
→	rows 접근
→	예외 처리
→	반복문과 종료 조건
→	sleep 과 backoff

SO WHAT data_path와 pagination이 빠지면 앞장만 받고 끝납니다. 이 둘이 조용한 실패의 단골입니다.

MCP는 에이전트에게 API 문서 대신 도구를 쥐여주는 표준입니다.

Model Context Protocol. 도구 서버가 API를 감싸고, 에이전트는 도구를 호출합니다



SO WHAT 표를 찾을 땐

```
New MCP server found in this project: korean-stat
MCP servers may execute code or access system resources. All tool calls require approval. Learn more in the MCP documentation.

Use this MCP server
> Use this and all future MCP servers in this project
Continue without using this MCP server

Enter to confirm · Esc to cancel
```

Source: modelcontextprotocol.io · seolcoding/korean-stat-mcp README (통계표 검색 · 메타데이터)

KOSIS 표 번호와 파라미터를 문서 대신 도구에게 묻습

10:42 · 2교시의 진짜 통증은 문서 읽기가 아니라 tblId · itmId · objL1 찾기입니다

TERMINAL · claude (korean-stat-mcp 연결됨)

> 합계출산율 시도별 연간 통계표를 찾아서 요청에 필요한 파라미터를 알려줘.

도구 호출: 통계표 검색 "합계출산율" → 3건. 인구동향조사 시도별 표를 고릅니다.

도구 호출: 메타데이터 조회 → 항목 T10(합계출산율), 분류 objL1 시도, 주기 Y.

orgId 101 · tblId DT_1B81A17 · itmId T10 · objL1 ALL · prdSe Y (예시)

> 이 값으로 references/api-registry.md 의 KOSIS 명세서를 채워.

명세서에 파라미터를 채웠습니다. 실제 호출 1건으로 검증할까요?

도구가 찾아준 값도 주장입니다. 검증 호출은 그대로 합니다.

SETUP

저장소를 열면 서버가 같이 잡힙니다

.mcp.json (저장소 루트)

```
{ "mcpServers": { "korean-stat": {
  "command": "korean-stat-mcp",
  "env": { "KOSIS_API_KEY": "${KOSIS_API_KEY}" } } } }
```

- 1 pip install korean-stat-mcp
- 2 환경변수 KOSIS_API_KEY 설정
- 3 VS Code 에서 저장소 열기 → claude 실행



안 되는 분은 감사 화면으로 따라오고, 명세서 값은 채팅창에 공유합니다.

```
MCP config diagnostics
For help configuring MCP servers, see: https://code.claude.com/docs/en/mcp

[Contains warnings] Project config (shared via .mcp.json)
Location: /Users/muni/Documents/Joohye's Second Brain/Projects/2609_정책데이터파이프라인_실습/policy-data-pipeline-main/.mcp.json
[Warning] [korean-stat] mcpServers.korean-stat: Missing environment variables: KOSIS_API_KEY

Manage MCP servers
8 servers

Project MCPs (/Users/muni/Documents/Joohye's Second Brain/Projects/2609_정책데이터파이프라인_실습/policy-data-pipeline-main/.mcp.json)
> korean-stat · ✓ connected · 12 tools

User MCPs (/Users/muni/.claude.json)
pencil · ✓ connected · 13 tools

claude.ai
claude.ai Canva · ✓ connected · 34 tools
claude.ai Gmail · ✓ connected · 29 tools
claude.ai Google Calendar · ✓ connected · 9 tools
claude.ai Google Drive · ✓ connected · 11 tools

Built-in MCPs (always available)
claude-in-chrome · ✓ connected · 22 tools
computer-use · ○ disabled

https://code.claude.com/docs/en/mcp for help
```

SO WHAT 명세서의 가장 어려운 칸이 문서 대신 도구로 채워집니다. 검증 호출은 그대로 갑니다.

언어모델이 정리한 명세서는 호출 한 건으로 검증한 뒤에 씁니다.

문서와 응답이 다르면 응답이 맞습니다. 코드를 고치지 말고 명세서를 고칩니다

VERIFY LOOP



실제 호출 1건이 확인하는 네 가지

- 1 HTTP 200 과 JSON 파싱
- 2 응답 최상위 구조 일치
- 3 data_path 로 관측치 도달
- 4 필수 키 존재 · 페이지 여유

spec_worldbank.json 에 verified_at 과 검증 결과가 함께 저장됩니다. 이 파일이 4교시 소스 레지스트리의 항목이 됩니다.

SO WHAT 문서를 읽혔으면 반드시 한 번 때려보고 넘어갑니다.

세 줄이 빠지면 매번 다른 모양의 명세서가 나옵니다.

결과를 사람이 아니라 코드가 읽기 때문에 필요한 줄입니다

1 RULE

키를 그대로 쓰고,
추가하거나 빼지 마세요



출력 모양 고정

다음 셀의 코드가 같은 키를 기대합니다. 키가 바뀌면 파싱이 깨집니다.

2 RULE

문서에 없는 항목은
'문서에 없음'으로 두세요



지어내기 차단

이 줄이 없으면 그럴듯한 파라미터를 만들어 냅니다.
.호출에서 400이 납니다.

3 RULE

설명 없이 JSON만,
코드펜스도 붙이지 마세요



그대로 파싱

붙여 와도 걷어내는 코드는 있지만, 처음부터 안 붙는 게 안전합니다.

SO WHAT 명세서 양식을 고정하는 것 자체가 실패 방지 장치입니다.

수집 전에 결정표 한 장을 채우면 재수집이 사라집니다.

문서에서 시작하지 않고 연구 질문에서 시작해 파라미터까지 내려옵니다

결정 항목	우리 값	파라미터	빠뜨리면
필요 지표	합계출산율	indicator	
비교 대상	OECD 주요 7개국 + 한국	country	국가 추가하며 재수집
분석 기간	2015~2025	date	추세 구간 짧아 재수집
주기	연간		분기 자료와 집계 충돌
지역 단위	국가 (국내는 시도)	objL1	국내외 결합 키 불일치
단위	명		환산 누락
기준	확정치 우선, 잠정 표시		재현 불가

TOP DOWN



빠진 결정을 에이전트가 되묻는지 관찰합니다.

SO WHAT 빠뜨리면 열은 전부 데이터를 다시 받아야 하는 사유입니다. 채우는 데 10분, 안 채우면 반나절.

03

LLM Agent 활용 API 호출 코드 구동 및 정제

13:00~15:00 · 어떻게 믿을 수 있게 가져오는가

표준 스키마는 바뀌지 않습니다

숫자를 읽게 하지 말고, 숫자를 읽는 코드를 짜게 하십시오.

언어모델이 개입할 자리는 코드를 만드는 단계입니다

값을 읽히기

코드를 짜게 하기

재현성

같은 질문에 매번 다른 답이 나올 수 있음



같은 입력에 같은 출력

검증

원문과 눈으로 대조하는 것 외에 방법 없음



단위 테스트로 검사 가능

비용

행 수에 비례해 늘어남



한 번 만들면 끝

틀렸을 때

조용히 틀림, 아무도 모름



예외로 드러남

값을 다루는 단계에 언어모델을 두면 재현성, 검증, 비용, 실패 양상 네 가지가 동시에 나빠집니다.

SO WHAT 오늘 실습은 전부 이 원칙대로 움직입니다. 에이전트는 코드를 쓰고, 여러분은 결과를 검증합니다.

에러 없이 틀린 숫자가 나오는 실패가 제일 위험합니다.

오후 내내 이 넷을 방어합니다

1 조용한 실패

증상 0건을 받았는데 정상 종료



방어 행 수 0이면 예외를 던진다

2 부분 수집

증상 첫 쪽만 받고 끝, 분석은 반쪽으로



방어 메타의 total과 받은 행 수를 대조

3 스키마 드리프트

증상 응답 키가 바뀌어 값이 통째로 사라짐



방어 필수 키가 없으면 비우지 말고 멈춤

4 무한 재시도

증상 실패한 요청을 끝없이 반복



방어 재시도 횟수 제한과 백오프

SO WHAT 자동화의 목표는 실패했을 때 조용하지 않은 것입니다.



오른쪽으로 갈수록 에이전트 몫은 줄고 검증 몫은 늘니다.


어디서 가져오느냐에 따라 에이전트에게 맡길 수 있는 범위가 다릅니다

	API	웹크롤링	내부 연구데이터
계약	문서화된 스키마	없음. 화면 구조가 계약	사람이 만든 표
접근 권리	이용약관 · 인증키 · 호출 제한	robots.txt · 저작권 · 서버 부하	내부 규정 · 개인정보 · 반출 금지
실패 양상	시끄러움 (HTTP 코드)	조용함 (빈 결과)	조용함 (셀 밀림 · 단위 혼재)
에이전트 몫	코드 생성 거의 전부	셀렉터 탐색 · 구조 변화 감지	헤더 해석 제안
사람 몫	파라미터 설계	크롤링해도 되는가	이 값이 정말 그 값인가
재현성	높음	낮음 (스냅샷 필수)	중간 (파일 버전)
결측 표기	null / 코드	빈 셀 · 텍스트	'.' · 공란 · '비공개'
검증 몫			

SO WHAT 붙이는 건 4교시입니다. 지금은 셋을 각각 표준 스키마까지만 옮깁니다.

실패를 먼저 나열시킨 코드만 일곱 장애를 조용히 넘기지 않습니다.

같은 API, 같은 목표. 프롬프트에 한 줄을 더한 결과 (exercises/03/fake_api.py 실측)



KEY INSIGHT

3 → 0

조용한 실패 건수 (7개 장애 중)

- empty 0건인데 정상 종료
- paged 첫 쪽만 받고 종료
- drift 지역 정보 전부 소실

주황이 숫자가 나오는데 틀린 경우입니다. 에러가 안 나서 아무도 모릅니다.

SO WHAT 중단은 좋은 결과입니다. empty와 paged에서 멈추는지 확인합니다.

JSON, XML, CSV 응답 세 개가 열 개 컬럼 하나로 모입니다.

형식마다 결측 표기가 다릅니다. 전부 사유 코드로 옮깁니다

JSON

World Bank 식

결측 "value": null
NA_NOTSURVEYED

XML

공공데이터포털 식

결측 <value></value> 빈 태그
NA_NOTSURVEYED

CSV

KOSIS 내려받기 식

결측 '-' 또는 공란
사유를 사람이 정함

표준 스키마

Observation 데이터클래스

source

indicator_code

region_code

period

value

unit

vintage

retrieved_at

source_url

missing_reason

value 가 비어 있으면 missing_reason 이 반드시 있어야 하고, 없으면 행 생성 자체가 실패합니다.


XML 은 빈 태그에서 값이 조용히 사라지기 쉽습니다. 국내 공공 API 는 XML 이 흔합니다.

SO WHAT 결측 사유는 수집 시점에만 알 수 있습니다. 그때 안 적으면 영원히 모릅니다.

MCP 도구 결과는 모델 컨텍스트로 들어옵니다. 값을 읽히는 것입니다.

탐색 · 조회 · 검증은 도구로, 파이프라인은 코드로. 섞으면 재현성이 무너집니다

도구로 하는 일 (MCP)




경계 기준

행 수십 · 한 번 · 근거는 대화 안

여기서 찾은 값을 코드에 넘깁니다

코드로 하는 일 (파이프라인)



경계 기준

행 수천 · 매달 · 근거는 raw/ 파일

MCP 로 찾은 파라미터가 여기로 들어옵니다

SO WHAT 표를 찾을 땐 도구, 파이프라인은 코드. 대화 안에서 2천 행을 읽히는 순간 재현성이 사라집니다.

통계 · 공시 · 법령 세 소스가 이미 MCP 서버로 나와 있습니다.

전부 커뮤니티 서버입니다. 설치 전 코드 확인, 키는 환경변수, 기관 보안 정책 우선

소스	서버	인증	맞는 기관
KOSIS 통계	korean-stat-mcp (Python)	KOSIS 인증키	전 기관
DART 공시	korean-dart-mcp (npx)	OpenDART 키	KIET · KDI · KIEP
법제처 법령	korean-law-mcp (npx)	법제처 OC (이메일)	KLRI · KICJ · KIPA · KINU
공공데이터포털	opendata-mcp	포털 인증키	기관별 데이터셋

쓰기 전 확인 세 가지

코드 · 보안 스캔 확인

키는 환경변수로

내부 자료는 안 넘김

DEMO · korean-law-mcp

지어낸 조문을 도구가 잡습니다

"민법 제750조 손해배상, 근로기준법 제60조 제1항 연차, 상법 제401조의2 제7항, 형법 제9999조 가중처벌"



verify_citations

실존 민법 제750조 · 근로기준법 제60조 제1항

없음 상법 제401조의2 제7항 (최대 제2항)

없음 형법 제9999조 (제1조~제372조)


법제처 공식 DB 와 교차검증. 우리 강의의 검증 원칙이 법령에도 그대로 통합니다.

SO WHAT 규범 계열 기관은 표보다 조문을 다룹니다. 검증 레이어의 소재만 다를 뿐 원칙은 같습니다.

에이전트는 셀렉터를 찾고, 크롤링은 코드가 합니다.

실제 사이트 대신 정책브리핑 구조를 본뜬 로컬 픽스처를 씁니다

분업



구조가 바뀐 페이지에 같은 코드를 돌리면

policy_page.html		17건
policy_page_v2.html (셀렉터 변경)		0건 · 에러 없음


방어: 기대 최소 행 수와 필수 필드를 검사에 넣어, 구조가 바뀌면 조용히 빈 결과를 내지 말고 멈춥니다.

SO WHAT API는 HTTP 코드가 소리를 내지만 크롤링은 그냥 조용합니다. 재현성은 스냅샷이 전부입니다.

내부 자료는 에이전트가 해석을 제안하고 사람이 확인한 뒤에만 변환합니다.

internal_panel.xlsx: 병합셀 · 2단 헤더 · 단위 혼재 · '.'와 공란 · 하단 각주

TWO STEPS



엑셀에서 조용히 틀리는 다섯 자리

- | | | | | | |
|----------|--------------|-----------------|----------|----------------|------------------|
| 1 | 병합셀 | 첫 행에만 값, 나머지 빈칸 | 2 | 2단 헤더 | 상위 헤더가 열 이름에서 빠짐 |
| 3 | 단위 혼재 | 명과 천명이 한 열에 | 4 | '.'와 공란 | 둘이 다른 뜻인데 같이 취급 |
| 5 | 하단 각주 | 데이터 행으로 읽힘 | | | |

WARNING

**에이전트가 파일을 읽으면
그 내용이 외부 모델로 갑니다**

- | | |
|--------------|----------------------------------|
| 실습 | 가공 샘플이라 괜찮습니다 |
| 실제 자료 | 기관 규정과 데이터 등급 확인 전에는 절대 읽히지 않습니다 |
| 대안 | 망분리 환경 · 사내 승인 모델 · 비식별 처리 후 사용 |

4교시 거버넌스로 이어집니다

SO WHAT 이 값이 정말 그 값인가는 에이전트가 판단할 수 없습니다.

04

다원 데이터 통합 파이프라인과 워크플로우 설계

15:00~17:00 · 어떻게 매번 다시 돌리는가

표준 스키마는 바뀌지 않습니다

프롬프트를 다듬는 것보다 규칙 파일에 맥락을 넣는 쪽이 큰 지렛대입니다.

같은 요청을 CLAUDE.md 없이, 그리고 있어 던져서 결과 차이를 봅니다

규칙 파일 없이

"KOSIS 출생아수 지표를 추가해줘"



- 코드체계를 매번 다르게 잡음
- 출처 우선순위를 임의로 정함
- 검증 없이 산출물까지 진행
- 결측을 빈칸으로 뭉갸

같은 사람이 시켜도 결과가 매번 다릅니다

CLAUDE.md · SKILL.md 있어

"KOSIS 출생아수 지표를 추가해줘"



- **region-codes.csv** 로 코드 통일
- **api-registry.md** 순서로 소스 확인
- **schema.md** 중단 조건 준수
- 판단한 건은 코드북 4절에 기록

누가 시켜도 같은 절차로 움직입니다

SO WHAT 규칙 파일에 넣는 것: 코드체계, 출처 우선순위, 금지사항, 중단 조건. 4교시 마지막 시연의 관전 포인트입니다.

세 갈래를 붙일 때 틀리는 자리는 값이 아니라 네 가지 키입니다.

행정구역코드와 법정동코드가 섞이면 뒤가 전부 틀립니다



SO WHAT 세 소스가 같은 키 네 개로 모이면 그 다음은 검증입니다.

규칙으로 먼저 처리하고, 판단한 건은 사전에 쌓아 다음부터 규칙으로 만듭니다.

매번 언어모델을 부르지 않아 비용과 안정성이 같이 잡힙니다


CYCLE



실습 샘플의 정책명 6종 중 4종은 규칙으로, 2종(첫만남이용권 · 산후조리 경비 지원)은 판단으로 처리되었습니다.

SAMPLE RUN

정책명 분류 6종



■ 규칙 4 ■ 판단 2 (미확인)

확인 후 사전 등록되면 다음 실행은 규칙 6, 판단 0

SO WHAT 판단은 줄어 들고 사전은 쌓입니다. 실행할수록 언어모델 의존이 낮아지는 구조입니다.

검증 실패는 코드가 막고, 산출물을 만들지 않습니다.

검사마다 실패했을 때 무엇을 할지가 붙어 있습니다

9 CHECKS

중단

행 수 0 아님

중단

기간 연속성 2015~2025

중단

표준 스키마 컬럼 존재

중단

결측에 사유 표기

중단

중복 키 없음

기록

전년 대비 변화율 30% 이내

중단

지표별 값 범위

기록

전국값과 시도 평균 정합

중단

시도 17개 전수 존재


중단이면 산출물 생성 단계로 넘어가지 않습니다. 기록이면 진행하되 코드북과 대시보드에 남깁니다.

```
python run.py --offline --break-check
```

값 하나를 99.9 로 바꿔 멈추는 장면을 봅니다

SAMPLE RUN

스냅샷 실행 검증 결과



확인 필요 1건은 세종 2016년 급변으로, 수업용 샘플에 일부러 심은 이상치입니다. 원문 대조 절차를 보여주는 장치입니다.

SO WHAT 검증을 사람 눈에 맡기지 않는 것이 요점입니다. 중단 조건은 [references/schema.md](#) 에 있습니다.

언어모델이 판단한 건은 전부 미확인으로 남고, 확인은 연구자가 합니다.

코드북은 실행할 때마다 다시 생성됩니다. 사람의 성실성에 기대지 않습니다

WHY AUTO

사람이 나중에 쓰는 코드북은
안 씁니다. 써도 어긋납니다

심의·감사	이 숫자 어디서 났습니까에 대한 답변서
인수인계	담당자가 바뀌어도 데이터가 살아남음
보고서 부록	NKIS 등재와 데이터 제출에 그대로

실행마다 재생성 = 항상 데이터와 동기화

codebook.md · 4. 판정이 필요했던 항목

원문	제안된 분류	근거	확인
첫만남이용권	현금성 지원	지자체 안내문의 지급 방식 기술	미확인
산후조리 경비 지원	현금성 지원	사후 정산 방식 명시	미확인

확인이 끝나면



전통적인 코드북에는 없는 절입니다. AI가 개입한 지점을 흐려두면 연구 신뢰도가 무너집니다.


KEY TAKEAWAY AI가 판단한 건 전부 여기 남습니다. 확인은 여러분이 합니다.

지표 하나를 추가하는 일곱 단계가 한 문장으로 끝납니다.

16:10 · 이 강의에서 가장 보여드리고 싶은 장면

> KOSIS 출생아수 지표를 파이프라인에 추가해. SKILL.md 절차대로 진행해.

에이전트가 움직이는 순서 (SKILL.md 절차)



6번에서 멈추면 검사를 느슨하게 고쳐 통과시키지 않습니다. 원인을 먼저 보고하고, 임계값을 바꿔야 하면 근거를 제시하고 확인을 받습니다.

SO WHAT 4분 뒤 대시보드가 바뀝니다. 방금 여러분이 만나절 쓰시던 작업입니다.

기관 망 환경에 따라 실행 방식만 고르면 됩니다.

월 · 분기 · 연간. 파이프라인은 같고 실행 장치만 다릅니다

1 로컬 스케줄러

조건

망분리 환경



방법

Windows 작업 스케줄러
또는 cron

가장 무난합니다. 연구자 PC에서 그대로 둡니다

2 GitHub Actions

조건

외부망이 열린 기관



방법

저장소에 워크플로우 파일
한 개 추가

실행 이력이 남고 팀이 함께 봅니다

3 수동 재실행

조건

공표일에 맞춰



방법

python run.py
한 줄

갱신 일정이 불규칙한 소스에 맞습니다

SO WHAT "매월 1일 새벽 3시에 실행하는 스크립트를 만들고 작업 스케줄러에 등록하는 방법을 알려줘" 까지 에이전트에게 맡깁니다.

결과물 네 가지가 매번 같은 자리에 다시 생깁니다.

대시보드는 파일 하나라 메일로 보내면 그냥 열립니다

out/dashboard.html

8

검증
통과

1


확인
필요

0

실패

292

행



out/panel.csv · out/codebook.md

분석용 패널과 코드북

패널은 표준 스키마 그대로, 코드북은 변수 정의 · 지표 목록 · 수집 이력 · 판정 항목 · 검증 결과 · 인용 유의사항 6절.

[raw/{실행일}/ 원본 스냅샷 함께 보관](#)

out/tables/

보고서용 표

시도별 합계출산율 표와 OECD 국제비교 표를 부록 형식으로. 출처 · 기준시점 · 단위가 표 하단에 자동으로 붙습니다.

[마크다운 + 엑셀](#)

SO WHAT 화면 맨 위가 큰 숫자가 아니라 검증 상태입니다. 30초 안에 알아야 할 건 이 데이터를 지금 써도 되는지입니다.

레지스트리와 소스 정의만 바꾸면 우리 기관 지표로 그대로 돌아갑니다.

스크립트 세 개는 손대지 않습니다

도메인	국내 소재	국제 소재
인구·가족	KOSIS 인구동향조사	World Bank SP.DYN.TFRT.IN
노동·고용	경제활동인구조사	OECD 고용 지표
환경·에너지	온실가스 인벤토리	World Bank EN 계열
교육	교육통계서비스	OECD Education at a Glance
보건	국민건강영양조사	OECD Health Statistics
해양·수산	해양수산통계	FAO 수산 통계

첫 행은 오늘 실습 소재. 나머지는 각 기관에서 지표 코드만 갈아끼웁니다.

바꾸는 것

references/api-registry.md

config/sources.yml

손대지 않는 것

collect.py · validate.py · report.py

옮기는 순서

- 1 레지스트리에 우리 소스 명세 등록
- 2 sources.yml 에 지표 추가
- 3 normalize.py 에 변환 함수 하나

SO WHAT KMI는 해양수산, KEI는 환경, KLI는 노동 지표로 바뀌어서 같은 스크립트를 씁니다.

수집 · 정제 · 검증 · 문서화는 자동화하고, 해석과 정책 판단은 남깁니다.

선을 강사가 먼저 긁습니다. AI는 그 앞단의 반복을 걷어내는 도구입니다

자동화하는 것

수집: API · 웹 · 내부 자료

정규화: 키 정합 · 단위 통일

검증: 중단 조건 · 급변 탐지

문서화: 코드북 · 대시보드 · 보고서용 표



파이프라인

매달 다시 돌고, 실패하면 소리를 냅니다

연구자에게 남기는 것

해석

인과추론

정책 판단

반출 원칙 세 가지

- 1 비공개 · 민감 자료는 외부 API 로 보내지 않습니다. 망분리 환경과 사내 승인 모델을 먼저 확인합니다
- 2 이용약관과 robots.txt 를 지키고, 출처와 기준시점을 표기합니다
- 3 정책연구 산출물에 AI 활용 범위를 명시합니다

도구는 바뀝니다. 저장소 구조와 규칙 파일과 스크립트 조합은 어떤 코딩 에이전트에서도 통합니다.

SO WHAT KINDA 플랫폼도 특정 모델에 고정하지 않는 플러그인 구조를 택했습니다. 종속을 줄이는 게 공공 인프라의 기본입니다.

이 분야는 프리프린트로 굴러갑니다. 빠른 만큼 덜 검증됐습니다.

2022년 정제 연구에서 2026년 에이전트 벤치마크까지



마무리

에이전트에게 데이터를 맡기지 말고, 파이프라인을 짜게 하십시오.

값을 읽게 하지 말고 값을 읽는 코드를 짜게 한다

검증 실패는 코드가 막는다

AI가 판단한 건 미확인으로 남기고 확인은 연구자가 한다